

METHODOLOGIE ET RESULTATS

Challenge ENS

Prédiction des rendements de fin de session du marché des actions américain



INSIGHT.DATA.CLARITY.



Université
de Rennes

I - CONTEXTE

Les marchés financiers génèrent une grande quantité de données intraday.

Le marché américain est l'un des plus liquides au monde et fournit de nombreuses opportunités d'investissement.

Les deux dernières heures de la session (entre 14h et 16h) sont les plus liquides de toutes. C'est la période préférée pour acheter ou vendre une grande quantité d'actifs car les conditions de marché sont meilleures.

C'est pourquoi estimer à l'avance le comportement d'un actif sur cette période permet d'optimiser l'ensemble de son portefeuille.


II – OBJECTIF DU PROJET

Prédire la direction du rendement de fin de session (14h–16h) à partir des rendements observés entre 9h30 et 14h.

III – VARIABLE CIBLE

La variable cible « reod » prend trois valeurs :

Classe	Signification	Proportion
-1	Baisse significative	30.1%
0	Variation faible	41.2%
1	Hausse significative	28.7%



La distribution des classes est équilibrée avec une légère dominance de la classe 0.

La structure est favorable pour l'entraînement des modèles de classification.

IV – DESCRIPTION DES DONNÉES

Chaque observation correspond à : une action x un jour.

Variables disponibles :

- 53 rendements intraday
- identifiant action
- identifiant jour

Taille du dataset : $\approx 843\,000$ observations.

V – STRUCTURE DES DONNÉES

Les rendements sont observés toutes les 5 minutes.

Exemples :

- r0 : 9h30–9h35
- r10 : 10h20–10h25
- r52 : 13h55–14h00

Ces rendements sont exprimés en points de base (bps).


VI – BENCHMARK

Benchmark fourni : 41.74 %

Un modèle aléatoire : $\approx 33 \%$

Objectif : dépasser le benchmark.

VII – PIPELINE DE MODELISATION



VIII – POURQUOI LE FEATURE ENGINEERING ?

Les rendements intraday contiennent :

- du bruit
- une structure temporelle
- de la volatilité


Le feature engineering permet de transformer les données brutes en variables plus informatives.

1) STATISTIQUES GLOBALES

Objectif : Capturer la distribution globale des rendements.

Variable	Résultat statistique	Interprétation
count	10834226.00	Dataset très volumineux → Bon pour entraîner un modèle.
mean	19.12	Moyenne pas représentative de la distribution réelle → Influencée par les outliers.
std	31969.05	Volatilité élevée à cause des outliers.
min	-9922.19	Variation importante sur un intervalle de 5 min
25%	-8.06	25% des rendements sont inférieurs à -8 bps.
50%	0.00	Rendements centrés autour de zéro → Typique des marchés financiers.
75%	7.76	75% des rendements sont inférieurs à 7.7 bps.
max	75160000.00	Valeurs extrêmes qui peuvent provenir d'erreurs de cotations ou d'évènements de marché.

Conclusion : les rendements intraday sont faibles mais très bruités.



1. Les rendements sont centrés autour de 0 (normal en finance).
2. La distribution est en cloche (quasi-gaussienne).
3. Présence de queues épaisses (il existe des mouvements brusques du marché).

2) MOMENTUM

Objectif : Capturer la dynamique récente du marché.

index ▼	last_return	last3_mean	last5_mean	momentum_short	momentum_last10
std	19.681442000442644	14.359654045371036	12.347451516921945	26.456991740908236	10.343633420577452
min	-990.99	-990.99	-990.99	-490.13	-990.99
mean	-0.010072839353963758	0.049427856989858146	0.0737881124597209	-0.13585259562134466	-0.11647907194892428
max	769.23	1165.94	846.795	720.62	1232.35
count	202775.0	214754.0	218579.0	193210.0	221858.0
75%	5.395	3.84	3.2620000000000005	9.4	2.366
50%	0.0	0.0	0.0	0.0	0.0
25%	-5.53	-3.7133333333333334	-2.992	-9.84	-2.399

last_return : dernier rendement observé → Rendement le plus récent avant la prédiction.

last3_mean : moyenne des 3 derniers rendements → Capture la dynamique très court terme.

last5_mean : moyenne des 5 derniers rendements → Permet de lisser les fluctuations intraday.

momentum_short : différence entre r52 et r48 → Mesure l'accélération récente du marché.

momentum_last10 : moyenne des 10 derniers rendements → Capture la tendance sur la dernière heure.

- Les variables de momentum sont centrées autour de zéro → absence de tendance forte dans les rendements intraday.
- Les variations observées dans les quartiles indiquent la présence de dynamiques de court terme exploitables par les modèles de ML.

3) STRUCTURE INTRADAY

Objectif : Capturer les changements de tendance pendant la séance.

	morning_mean	midday_mean	preclose_mean	intraday_shift
count	2.276330e+05	226521.000000	221858.000000	2.213070e+05
mean	9.032068e+01	-0.191726	-0.116479	-5.716410e+01
std	2.205509e+04	10.247753	10.343633	1.834057e+04
min	-2.181430e+03	-606.690000	-990.990000	-7.516007e+06
25%	-7.758000e+00	-2.673500	-2.399000	-6.462000e+00
50%	-1.180000e-01	0.000000	0.000000	4.600000e-01
75%	5.578000e+00	2.557500	2.366000	8.638000e+00
max	7.516007e+06	662.850000	1232.350000	2.181430e+03

La dispersion est légèrement plus élevée en début de séance, ce qui est cohérent avec la littérature financière : l'ouverture du marché est généralement plus volatile.

Les statistiques montrent que les rendements intraday sont globalement centrés autour de zéro. Les variations sont faibles mais certaines actions peuvent présenter un changement de dynamique entre le début et la fin de séance.

Variable	25%	Median	75%	Interprétation
morning_mean	-7.76	-0.12	5.58	Rendements du début de séance.
midday_mean	-2.67	0	2.56	Marché stable au milieu de journée.
preclose_mean	-2.39	0	2.37	Faibles variations avant clôture.
intraday_shift	-6.46	0.46	8.63	Différence début vs fin de séance.

4) VOLATILITÉ

Objectif : Capturer l'intensité des fluctuations de prix.

	vol_total	vol_last10	vol_first10	vol_ratio
count	2.278690e+05	218220.000000	2.231140e+05	2.157370e+05
mean	1.658134e+02	14.808259	3.542724e+02	3.053664e+05
std	3.155174e+04	15.079524	7.044671e+04	4.281721e+06
min	0.000000e+00	0.000000	0.000000e+00	0.000000e+00
25%	1.355152e+01	6.784069	1.838171e+01	2.352351e-01
50%	2.045926e+01	11.101744	2.995789e+01	3.681320e-01
75%	3.271050e+01	18.152415	5.003245e+01	5.631702e-01
max	1.032402e+07	548.743146	2.376768e+07	3.314563e+08

vol_total : volatilité globale de la séance.

vol_last10 : volatilité en fin de séance.

vol_first10 : volatilité en début de séance .

vol_ratio : évolution de la volatilité.

Variable	25%	Median	75%
vol_total	13.55	20.46	32.71
vol_last10	6.78	11.10	18.15
vol_first10	18.38	29.96	50.03
vol_ratio	0.24	0.37	0.56

Les résultats montrent que la volatilité est généralement plus élevée en début de séance ce qui correspond aux comportements observés sur les marchés financiers.

5) PRESSION ACHETEURS/VENDEURS

Objectif : Mesurer l'équilibre entre les mouvements haussiers et baissiers au cours de la séance.

	pos_ratio	neg_ratio	pos_last10
count	229074.000000	229074.000000	229074.000000
mean	0.338832	0.343414	0.319846
std	0.157746	0.156434	0.205609
min	0.000000	0.000000	0.000000
25%	0.226415	0.245283	0.200000
50%	0.377358	0.377358	0.300000
75%	0.452830	0.452830	0.500000
max	0.773585	0.792453	1.000000

pos_ratio : pression acheteuse globale.

neg_ratio : pression vendeuse.

Pos_last10 : pression acheteuse en fin de séance.

Variable	25%	Median	75%
pos_ratio	0.23	0.38	0.45
neg_ratio	0.25	0.38	0.45
pos_last10	0.20	0.30	0.50

Les résultats montrent que les proportions de rendements positifs et négatifs sont relativement équilibrées ce qui reflète un marché intraday globalement stable.

6) TREND

Objectif : Mesurer la tendance des rendements intraday.

	trend	trend_last10	trend_acceleration
count	229074.000000	229074.000000	229074.000000
mean	-1.178990	0.036562	1.213659
std	366.945388	1.682206	366.949539
min	-151507.903851	-42.337697	-37.430473
25%	-0.060736	-0.467818	-0.408627
50%	0.000000	0.000000	0.000000
75%	0.076207	0.527879	0.422143
max	19.416057	66.536000	151508.256457

trend : tendance globale de la séance.

trend_last10 : tendance récente.

trend_acceleration : pression acheteuse en fin de séance

Variable	25%	Median	75%
trend	-0.06	0	0.08
trend_last10	-0.47	0	0.53
trend_acceleration	-0.41	0	0.42

Les statistiques montrent que les tendances sont généralement faibles ce qui reflète le caractère bruité des rendements intraday.

IX – MODÈLES (1/2) : LIGHTGBM

LightGBM est un algorithme de Gradient Boosting basé sur des arbres.

Principe : chaque arbre corrige les erreurs du précédent.

Formules : $F_{\{t\}}(x) = F_{\{t-1\}}(x) + \eta h_t(x)$ où : $h_t(x)$ est un nouvel arbre et η est le learning rate.


Avantages : très performant sur données tabulaires, rapide et capable de capturer des relations non linéaires.

Limites : sensible au feature engineering, risque d'overfitting, difficulté d'interprétation et dépendance aux hyperparamètres.

IX – MODÈLES (1/2) : LIGHTGBM

Scores CV : [0.47248487388354854, 0.47078236726996514, 0.4744362083868095]
Score moyen : 0.47256781651344104

Mesure	Valeur
Accuracy CV moyenne	0.4726
Benchmark	0.4174



```
▶ y_pred = lgb.predict(X_feat)  
print(pd.Series(y_pred).value_counts(normalize=True))
```

```
... 0    0.553494  
   -1   0.263160  
    1   0.183347
```



Le modèle prédit bien les classes.

IX – MODÈLES (2/2) : RANDOM FOREST

Random Forest est un modèle basé sur un ensemble d'arbres de décision.

Principe : bootstrap, construction d'un arbre de décision, répétition du processus pour des arbres, agrégation des prédictions.

Formule : $\hat{f}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$ où : T = nombre d'arbres et $f_t(x)$ = prédiction du t-ième arbre.


Prédiction finale : vote majoritaire pour la classification ($\hat{y} = \text{mode}(f_1(x), f_2(x), \dots, f_T(x))$).

Avantages : robuste au bruit, peu sensible à l'overfitting.

Limites : moins performant que les méthodes de boosting.

IX – MODÈLES (2/2) : RANDOM FOREST

Scores CV RF : [0.47256345111186776, 0.4687262631289452, 0.4726682207496268]
Score moyen RF : 0.4713193116634799



Mesure	Valeur
Accuracy CV moyenne	0.4713
Benchmark	0.4174

```
▶ y_pred = rf.predict(X_feat)
print(pd.Series(y_pred).value_counts(normalize=True))
```

...	0	0.565202
	-1	0.321551
	1	0.113247

Le modèle prédit bien les classes.

X- VALIDATION CROISÉE

Méthode utilisée : Stratified K-Fold (K = 3)

Principe :

- Le dataset est divisé en 3 folds
- à chaque itération :
- 2 folds pour l'entraînement
- 1 fold pour la validation

Le processus est répété 3 fois.

Le score final est la moyenne des scores obtenus.

Objectifs :

- évaluer la robustesse
- éviter l'overfitting
- choisir les paramètres

```
▶ cv = StratifiedKFold(n_splits=3, shuffle=True, random_state=42)

scores_lgb = []
scores_stack = []

print("Début CV")

for fold, (train_idx, val_idx) in enumerate(cv.split(X_feat, y)):

    print("Fold", fold + 1)

    X_tr = X_feat.iloc[train_idx]
    X_val = X_feat.iloc[val_idx]

    y_tr = y.iloc[train_idx]
    y_val = y.iloc[val_idx]

    lgb.fit(X_tr, y_tr)
    rf.fit(X_tr, y_tr)

    proba_lgb = lgb.predict_proba(X_val)
    proba_rf = rf.predict_proba(X_val)

    y_lgb = lgb.classes_[np.argmax(proba_lgb, axis=1)]

    scores_lgb.append(accuracy_score(y_val, y_lgb))
```



XI – COMBINAISON DES MODÈLES

Les probabilités des deux modèles sont combinées :

- $\text{proba_stack} = w \times LGBM + (1 - w) \times RF$

avec : w le poids attribué à LightGBM et $1 - w$ le poids attribué à RF.



Recherche du poids optimal par validation croisée :

Poids LGBM	Poids RF	Score
0.5	0.5	0.4743
0.6	0.4	0.4744
0.7	0.3	0.4743

```
weights = [0.5, 0.6, 0.7, 0.8]
for w in weights:
    scores = []
    for train_idx, val_idx in cv.split(X_feat, y):
        X_tr = X_feat.iloc[train_idx]
        X_val = X_feat.iloc[val_idx]
        y_tr = y.iloc[train_idx]
        y_val = y.iloc[val_idx]
        lgb.fit(X_tr, y_tr)
        rf.fit(X_tr, y_tr)
        proba_lgb = lgb.predict_proba(X_val)
        proba_rf = rf.predict_proba(X_val)
        proba_stack = w * proba_lgb + (1 - w) * proba_rf
        y_stack = lgb.classes_[np.argmax(proba_stack, axis=1)]
        scores.append(accuracy_score(y_val, y_stack))
    print("Poids LGBM =", w, "Score =", np.mean(scores))
```

Complémentarité des poids : $w_{\{RF\}} = 1 - w_{\{LGBM\}}$ donc si $w_{\{LGBM\}} = 0.6$ alors $w_{\{RF\}} = 0.4$

Pourquoi le stacking fonctionne ici ?



- LightGBM capte surtout le momentum et la structure intraday.
- Random Forest capte davantage la volatilité et la pression de marché.

Les erreurs ne sont pas identiques donc la combinaison améliore la robustesse.

XII – EVOLUTION DES SOUMISSIONS

Soumissions de mon équipe

Vous pouvez sélectionner une soumission spécifique pour les classements. Si aucune soumission n'est sélectionnée, votre meilleure soumission sur le score public sera automatiquement utilisée.

Rang	Date	Méthode	Paramètres	Score public	Sélection
1	5 mars 2026 20:38	LGB et RF test	proba_stack_test = 0.6 * proba_lgb_test + 0.4* proba_rf_test + recalibrage + features	0,42198690449311355	Sélectionné Effacer
2	5 mars 2026 15:25	LGB et RF Test	proba_stack_test = 0.7 * proba_lgb_test + 0.3* proba_rf_test +features	0,42174079927748925	Select
3	4 mars 2026 10:32	LGB et RF Test	proba_stack_test = 0.7 * proba_lgb_test + 0.3* proba_rf_test + recalibrage (proba_adj)	0,41550237073831564	Select
4	4 mars 2026 10:31	LGB et RF Test	proba_stack_test = 0.7 * proba_lgb_test + 0.3* proba_rf_test	0,4146466470986679	Select
5	3 mars 2026 03:24	LGB RF test	proba_stack_test = 0.9 * proba_lgb_test + 0.1 * proba_rf_test	0,40638293068412734	Select
6	3 mars 2026 02:58	LGB et RF test	proba_stack_test = 0.85 * proba_lgb_test + 0.15 * proba_rf_test	0,3535493339354256	Select

Observations :

- Les premières combinaisons donnent un score autour de 0.35 – 0.40.
- L’ajout des features améliorent significativement la performance.
- L’optimisation des poids du stacking (0.6 LGBM / 0.4 RF) améliore encore le score.
- Le recalibrage des probabilités permet d’améliorer la prédiction directionnelle.

XII – SCORE FINAL

Prédiction des rendements de fin de session du marché action américain
par CFM

Introduction

Classement public

Classement privé

Classement académique public

Classement académique privé

Soumissions

Il s'agit du classement académique public lié au cours M2IEF2025-2026, actif durant toute la durée du cours. Il utilise le score public (le score obtenu par les participants sur la partie publique du jeu de données) pour établir le classement.

Rang	Date	Participant(s)	Score public
1			
2	5 mars 2026 20:38	Ines.tapoayi & romain.clv	0,4220
3			
4			
5			
6			
7			
8	-	benchmark	0,4174

XIV – ANALYSE DES RÉSULTATS

Les performances proviennent principalement :

- Du feature engineering : les variables construites (momentum, volatilité, structure intraday, pression acheteur / vendeur) capturent mieux la dynamique du marché.
- De LightGBM : le modèle capte efficacement les relations non linéaires dans les données financières.
- De la combinaison des modèles (stacking) : LightGBM + Random Forest réduit la variance et améliore la robustesse des prédictions.

XV – ANALYSE DES ERREURS

Certaines observations restent difficiles à prédire car :

- Les erreurs apparaissent principalement dans les périodes de forte instabilité du marché.
- Les signaux contradictoires intraday rendent la direction difficile à anticiper.
- Certaines actions présentent des dynamiques spécifiques non capturées par les features.

Cela explique les limites du modèle.

XVI – CONCLUSION

Les données intraday contiennent une information prédictive exploitable pour anticiper la direction des rendements.

Le feature engineering permet de capturer plusieurs dimensions du marché.

Les modèles LightGBM et Random Forest permettent de capter des relations complexes dans les données.

La combinaison des modèles (stacking) améliore la robustesse et les performances.

Cette approche permet de dépasser le benchmark et d'améliorer les prédictions directionnelles.